Monitor de Riesgo Académico Saber 11

Proyecto — Entrega 1 · Despliegue de Soluciones Analíticas (MIAD)

Equipo: Mateo Ríos · Harol Perafan · Sebastian Vivas | 25 de octubre de 2026

Repositorio Git: [URL del repositorio GitHub] · Remoto DVC: [s3://bucket/saber11]

1. Problema y contexto

El examen Saber 11 del ICFES evalúa a todos los estudiantes que terminan la educación media en Colombia y su puntaje global (0–500) condiciona el acceso a la educación superior, a becas (p. ej. Generación E) y a créditos educativos. Los resultados muestran brechas persistentes asociadas al contexto del estudiante: en el periodo analizado, un estudiante de un colegio en Chocó tiene 5 veces más probabilidad de quedar en el cuartil inferior que uno de Bogotá (61 % vs 12 %).

Las secretarías de educación y los rectores cuentan con recursos limitados para programas de refuerzo (preparación pre-Saber, tutorías, conectividad). Hoy la focalización se hace con los resultados del año anterior, es decir, cuando el estudiante ya presentó la prueba. El problema es la falta de una herramienta que, con información disponible antes del examen (características del hogar y del colegio), identifique a tiempo a los estudiantes y colegios con mayor riesgo de bajo desempeño.

Por qué un modelo es útil: Un modelo supervisado entrenado con los resultados históricos permite estimar ese riesgo para cada estudiante de grado 11 al inicio del año escolar. Combinado con un tablero descriptivo, convierte los datos abiertos del ICFES en una lista priorizada y explicada de a quién y dónde intervenir.

2. Pregunta de negocio y alcance

¿Qué estudiantes (y colegios/municipios) tienen mayor riesgo de obtener un puntaje global bajo en Saber 11, dadas sus características socioeconómicas y del colegio, para priorizar intervenciones de refuerzo?

- **Usuarios:** secretarías de educación departamentales/municipales y rectores de colegios.
- **Componente descriptivo:** tablero con la distribución del riesgo por territorio, tipo de colegio y factores del hogar, y ranking de municipios/colegios prioritarios.
- **Componente predictivo:** (i) clasificador de riesgo, definido como puntaje global < percentil 25 nacional (210 puntos); (ii) regresor del puntaje global como complemento. Solo con variables conocidas antes de la prueba.
- **Entregable final:** modelo empaquetado, API de inferencia (FastAPI) y tablero (Dash) que consume la API, desplegados en contenedores Docker en AWS.
- **Fuera del alcance:** inferencia causal, diseño o evaluación de las intervenciones, datos individuales no públicos (notas, asistencia) y otras pruebas (Saber 3°, 5°, 9°, Pro).
- **Criterio de éxito:** AUC ≥ 0,75 y recall ≥ 0,70 en la clase de riesgo sobre un conjunto de prueba separado; tablero utilizable con filtros por territorio.

3. Conjunto de datos

Se usa el conjunto «Resultados únicos Saber 11» publicado por el ICFES en el portal de datos abiertos datos.gov.co (id kgxf-xxbe, API Socrata). Contiene un registro por estudiante evaluado desde 2010 con 51 columnas. Para esta entrega se toma el periodo más reciente publicado (20224, calendario A y B): 1.065.888 filas descargadas, que corresponden a 532.788 estudiantes únicos, 10.378 colegios y 1.114 municipios. La descarga es reproducible mediante el script src/download_data.py, que selecciona 35 columnas relevantes vía SoQL.

Grupo	Variables (ejemplos)	Uso
Estudiante	estu_genero, edad (derivada de la fecha de nacimiento), depto/municipio de residencia	Predictor

Hogar (fami_*)	estrato, educación de madre y padre, personas y cuartos del hogar, internet, computador, automóvil, lavadora	Predictor
Colegio (cole_*)	naturaleza (oficial/no oficial), zona, jornada, calendario, bilingüe, carácter, género, departamento y municipio, código DANE	Predictor / filtro
Resultados (punt_*)	lectura crítica, matemáticas, c. naturales, sociales, inglés (0–100), global (0–500)	Objetivo / descriptivo
Derivada	riesgo_bajo_desempeno = 1 si punt_global < P25 (210)	Objetivo

Calidad de datos. Se encontraron tres problemas de calidad que el pipeline (src/clean_data.py) resuelve: (1) la fuente publica cada registro dos veces, lo que se verificó contra la API con count(distinct estu_consecutivo) = 532.792, y se deduplica por estudiante; (2) cuatro pruebas tienen puntaje global 0 (anuladas) y se excluyen; (3) las variables del hogar tienen 4–7 % de nulos y cole_bilingue 18 %. Estos nulos se conservan para imputarlos como categoría «Sin información» en el modelado (Figura 1).

4. Exploración de los datos

La exploración completa está en notebooks/01_eda.ipynb. Se presentan los resultados más relevantes para la pregunta de negocio.

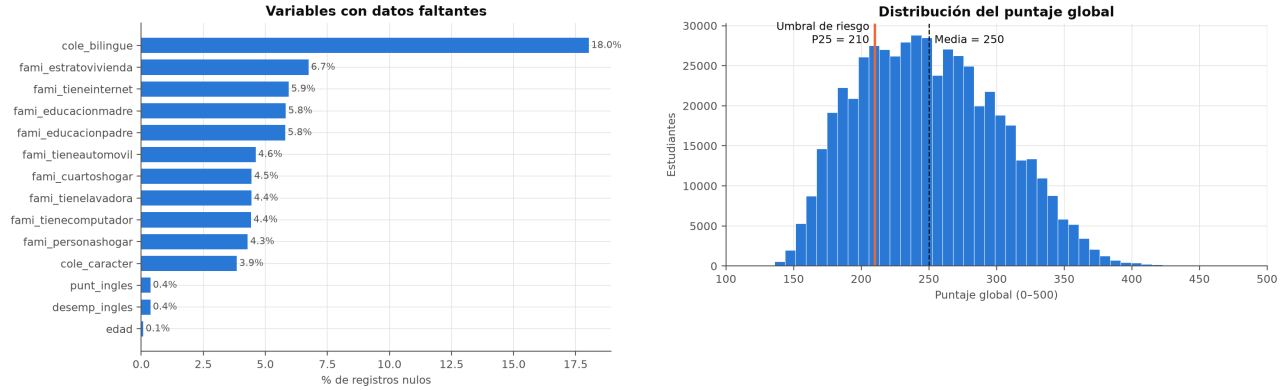


Figura 1. Variables con datos faltantes (izq.) y distribución del puntaje global con el umbral de riesgo P25 = 210 (der.).

Variable objetivo. El puntaje global tiene media 250 y desviación estándar 52, con una distribución aproximadamente normal y ligeramente sesgada a la derecha (máx. 477). Definir el riesgo como el cuartil inferior genera una clase positiva del 25 %. El desbalance es moderado, por lo que se evaluará con AUC y recall y se usará ponderación de clases. Los cinco puntajes por área tienen correlaciones de 0,68 a 0,81 con los demás y casi determinan el global, así que no se usarán como predictores: serían fuga de información.

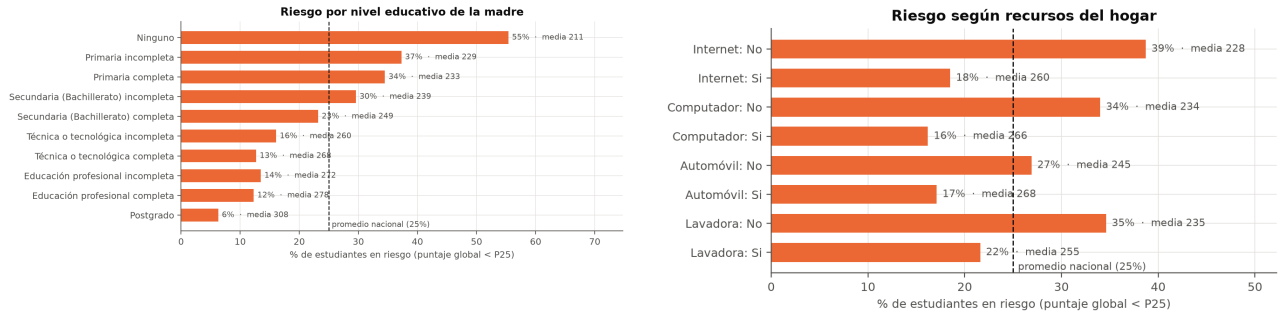


Figura 2. Tasa de riesgo por nivel educativo de la madre (izq.) y por recursos del hogar (der.). Línea punteada = 25 % nacional.

Factores del hogar. La educación de la madre es el factor con mayor asociación con el puntaje ($\eta^2 = 0{,}13$). El riesgo baja de forma monótona de 55 % (sin educación) a 6 % (posgrado). Los estudiantes sin internet o sin computador en casa tienen aproximadamente el doble de riesgo (39 % y 34 %) que quienes sí los tienen (19 % y

16 %). Estas variables son buenas candidatas para el modelo y apuntan a intervenciones concretas, como la conectividad.

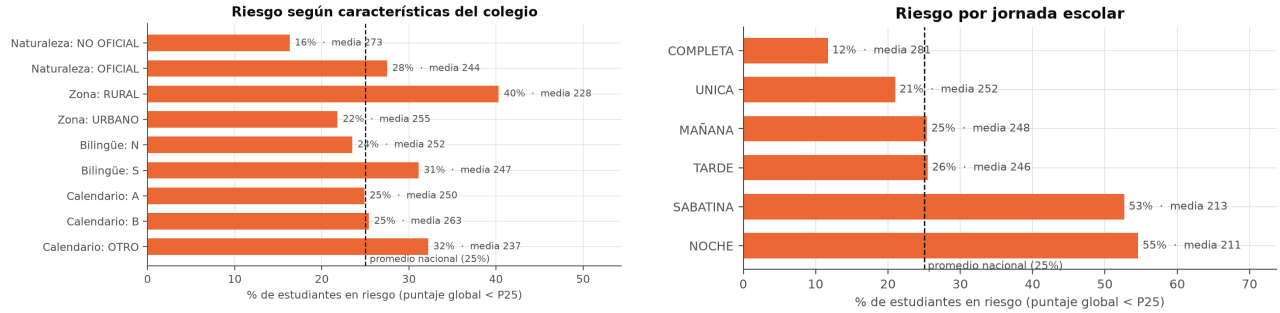


Figura 3. Tasa de riesgo según características del colegio (izq.) y jornada (der.).

Factores del colegio. Las jornadas nocturna y sabatina, que atienden principalmente a jóvenes en extraedad y adultos, tienen más de 50 % de riesgo, frente a 12 % en la jornada completa. Los colegios rurales (40 %) y los oficiales (28 % vs 16 % en los no oficiales) también concentran el riesgo. Calendario y bilingüismo casi no discriminan ($\eta^2 \approx 0$).

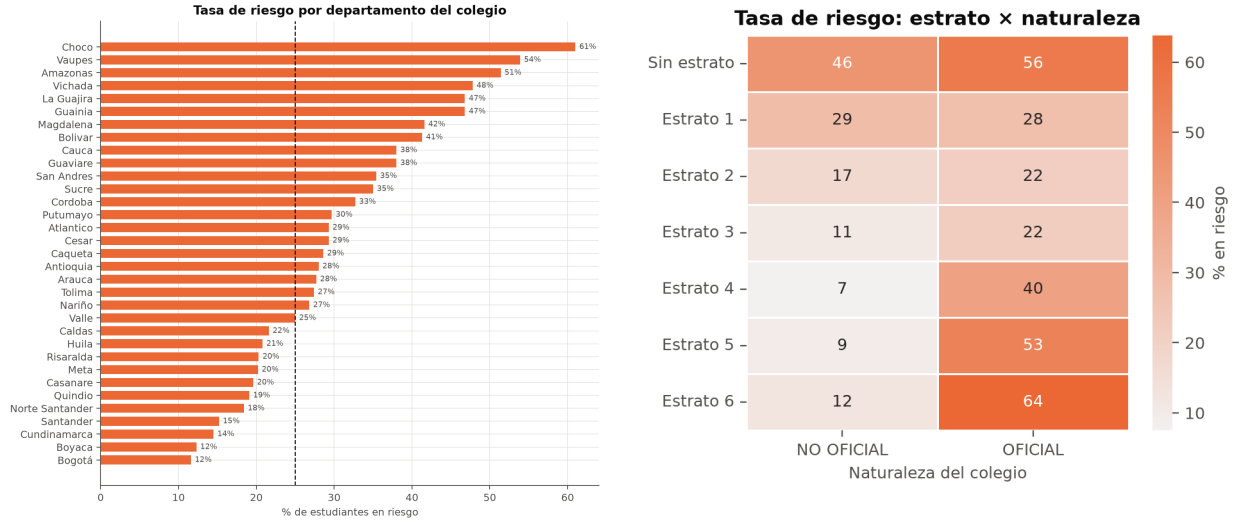


Figura 4. Tasa de riesgo por departamento (izq.) y por estrato × naturaleza del colegio (der.).

Territorio. La brecha territorial es muy marcada: Chocó (61 %), Vaupés (54 %), Amazonas (51 %) y La Guajira (47 %) frente a Boyacá (12 %) y Bogotá (12 %). Dentro de los departamentos el riesgo se concentra aún más: 115 municipios con al menos 100 evaluados y 1.172 colegios tienen 50 % o más de estudiantes en riesgo (p. ej. Bojayá 98 % y Timbiquí 86 %). Por eso el tablero debe permitir bajar a nivel de municipio y colegio.

Hallazgo de calidad. El riesgo por estrato no es monótono. En los colegios no oficiales baja con el estrato, como se espera (46 % → 12 %), pero en los oficiales sube en los estratos 4–6 (40–64 %). Se verificó que la anomalía no la explican las jornadas de adultos ni la edad, por lo que se atribuye a errores de autorreporte. El estrato se usará junto con variables más confiables y no de forma aislada.

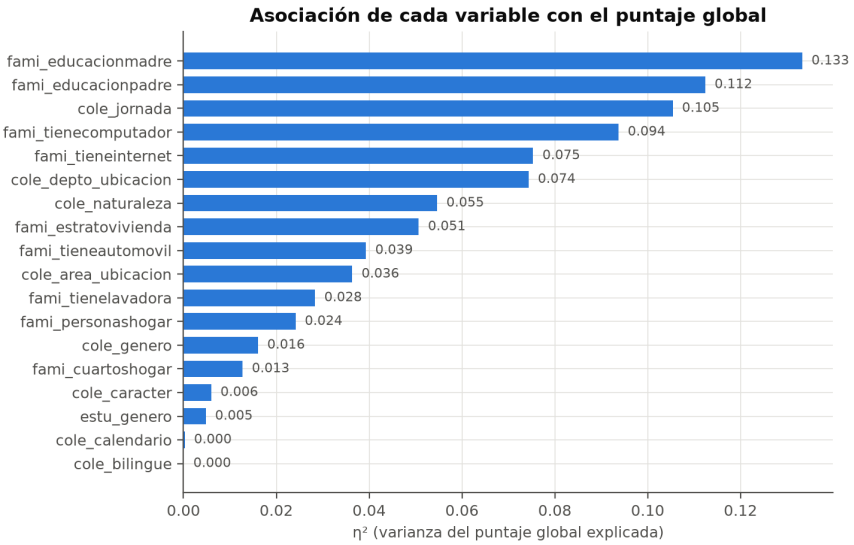


Figura 5. Proporción de la varianza del puntaje global explicada por cada variable (η^2).

Selección preliminar de variables. Las variables con más poder explicativo son la educación de los padres, la jornada, el acceso a computador e internet, el departamento y la naturaleza del colegio. Serán el núcleo del modelo. Género, calendario, bilingüismo y carácter aportan poco. Al combinar varias variables débilmente correlacionadas se espera superar el η^2 individual, lo que justifica un modelo multivariado (regresión logística como línea base y gradient boosting).

5. Maqueta del prototipo

El tablero tiene tres pestañas. Diagnóstico territorial responde dónde y a quién intervenir con datos descriptivos. Predicción de riesgo consume el modelo a través de la API. Priorización de colegios permite cargar un listado por lotes y exportar la lista priorizada. Los números de la maqueta son cifras reales del EDA; solo los valores del modelo (probabilidad y contribuciones SHAP) son ilustrativos.

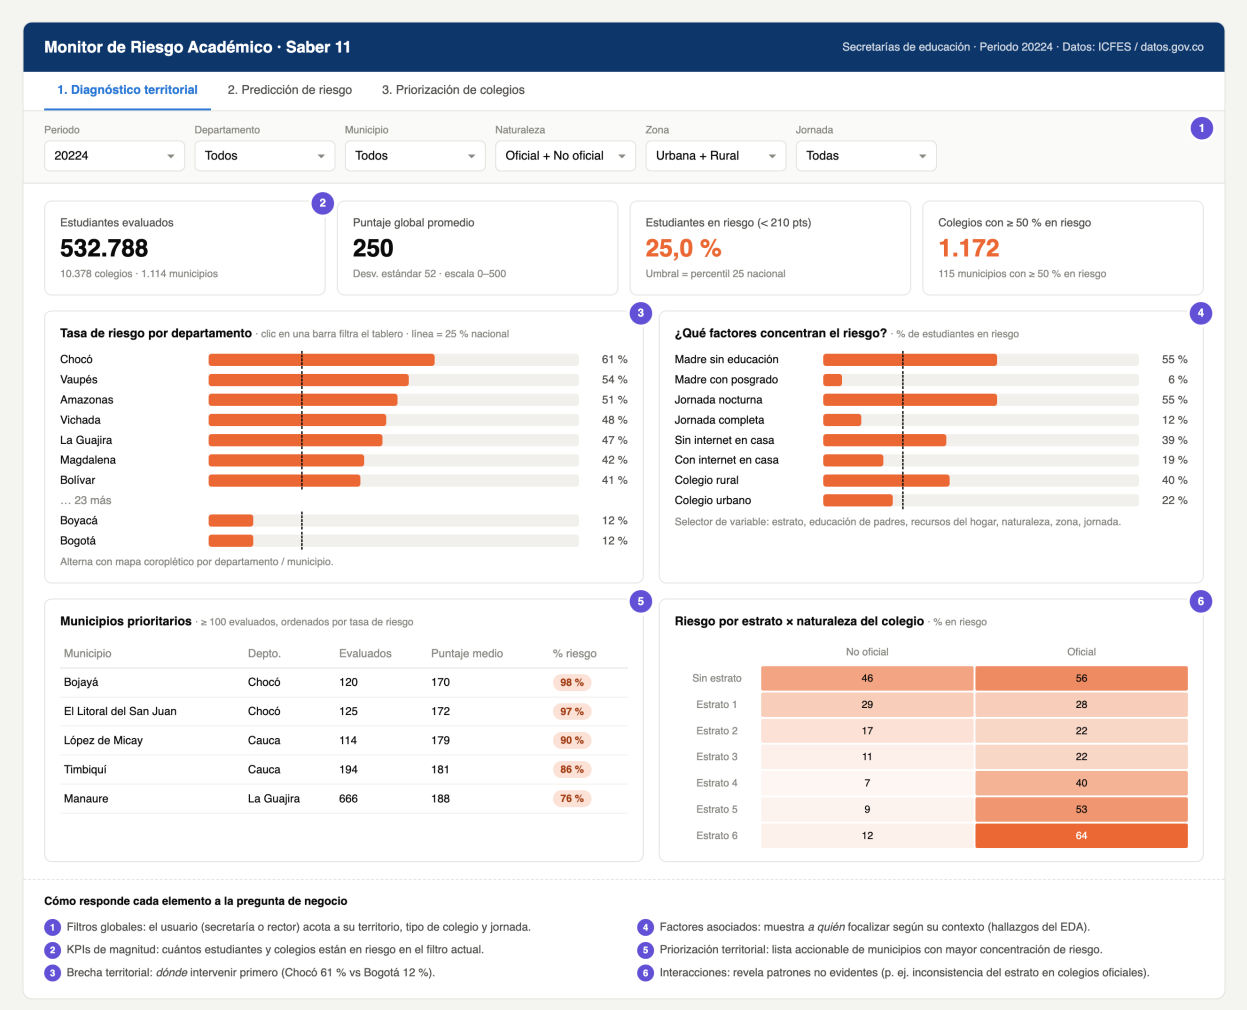


Figura 6. Vista 1 — Diagnóstico territorial: filtros (1), KPIs (2), riesgo por departamento (3), factores asociados (4), municipios prioritarios (5) e interacción estrato × naturaleza (6).

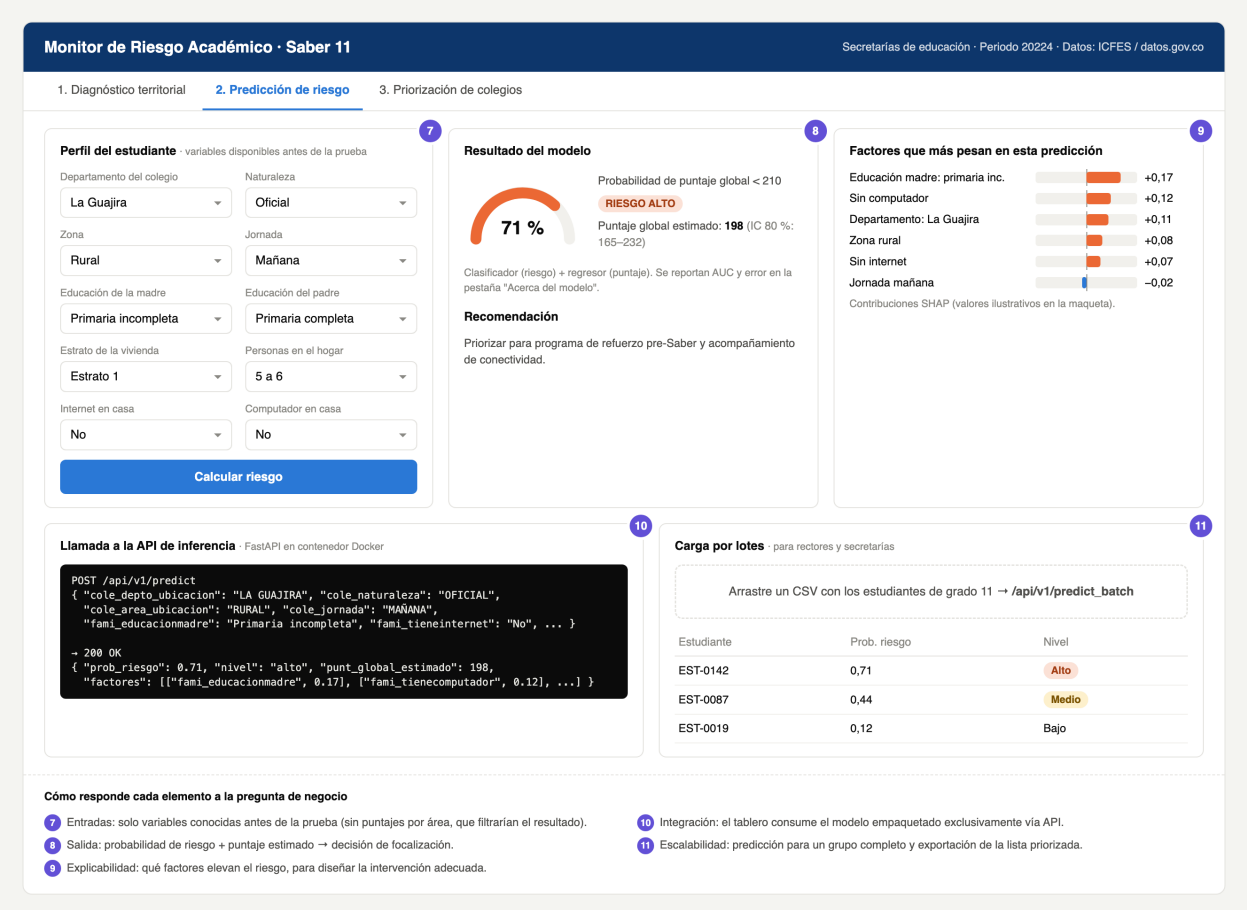


Figura 7. Vista 2 — Predicción: perfil del estudiante (7), probabilidad de riesgo y puntaje estimado (8), factores explicativos (9), contrato de la API (10) y predicción por lotes (11).

Iteración según los datos. La versión inicial de la maqueta (Semana 2) se ajustó con los hallazgos del EDA en cuatro puntos. (a) Se agregó el filtro de jornada y se resaltó en los factores, por su alto poder explicativo. (b) El formulario de predicción excluye los puntajes por área para evitar fuga de información. (c) Se añadió el nivel municipal y la lista de municipios prioritarios, porque el riesgo se concentra por debajo del nivel departamental. (d) Se incluyó la matriz estrato × naturaleza para hacer visible la inconsistencia del estrato.

6. Repositorios de código (Git) y datos (DVC)

Código en GitHub: [URL del repositorio GitHub]. Datos versionados con DVC en un remoto S3 ([s3://bucket/saber11]). Git solo almacena los metadatos (dvc.yaml, dvc.lock, .dvc/config); los archivos de datos (data/raw/saber11.csv de 292 MB y data/processed/saber11_clean.parquet de 15 MB) se suben con dvc push. El pipeline DVC tiene dos etapas, download y clean, y se reproduce con «dvc repro». Cualquier integrante obtiene los datos con «dvc pull».

Ruta	Contenido
src/download_data.py	Descarga paginada desde la API Socrata con reintentos
src/clean_data.py	Deduplicación, tipos, edad, normalización y variable objetivo
dvc.yaml / dvc.lock	Pipeline download → clean y hashes de los datos versionados
notebooks/01_eda.ipynb	Exploración de datos (14 figuras en reports/figures/)
mockup/	Maqueta HTML del tablero y capturas
docs/	Reportes de la entrega y su script generador

[Insertar capturas: (1) historial de commits en GitHub con los tres integrantes; (2) salida de «dvc push» / «dvc status -c»; (3) bucket S3 con los archivos de DVC.]

7. Próximos pasos

- Ampliar los datos a periodos anteriores (20194) para validar la estabilidad temporal del modelo.
- Entrenar la línea base (regresión logística) y gradient boosting con seguimiento de experimentos en MLflow.
- Construir la API (FastAPI) y el tablero (Dash), contenerizarlos con Docker y desplegarlos en AWS.